Divide, Vence y Clasifica: Un Marco Jerárquico para la Clasificación de Textos Científicos

Juliette Ninnie Lazo Vazquez
Facultad de Ciencas
Universidad Autonoma de Baja California
Ensenada, Baja California
juliette.lazo@uabc.edu.mx

I. Introducción

El crecimiento exponencial de la literatura científica ha generado un desafío monumental para la organización del conocimiento. Con repositorios como arXiv recibiendo miles de envíos mensuales, la clasificación manual se ha vuelto insostenible. Sin embargo, la automatización de esta tarea enfrenta obstáculos significativos: la alta dimensionalidad del lenguaje técnico, el desbalance extremo entre categorías y, crucialmente, la ambigüedad semántica entre disciplinas superpuestas (como el Machine Learning, que existe tanto en Ciencias de la Computación como en Estadística). Los enfoques tradicionales basados en frecuencia de palabras (TF-IDF) tienden a fallar al no capturar el contexto profundo necesario para distinguir estas sutilezas en un espacio de más de 150 subcategorías.

Para abordar este problema, este proyecto presenta un sistema de clasificación jerárquica ('Divide y Vencerás') potenciado por Deep Learning. En lugar de un clasificación plano tradicional, propongo una arquitectura de dos fases: un modelo general que dirige los documentos a macro-áreas (Física, Matemáticas, Finanzas, etc.), y un conjunto de modelos 'Especialistas' que determinan la sub-categoría final. El núcleo del sistema se basa en SPECTER, una arquitectura tipo Transformer entrenado con grafos de citas, capaz de generar embeddings que agrupan documentos por su relación semántica y no solo por coincidencia de palabras.

El desarrollo incluyó una rigurosa ingeniería de datos para estandarizar etiquetas históricas obsoletas y estrategias de fusión de clases para mitigar la confusión en áreas financieras. A través de este enfoque, logramos transformar un problema de clasificación masiva en una tarea modular eficiente. Los resultados demuestran la robustez del sistema, alcanzando un Top-3 accuracy del 78.2 por ciento, validando que la combinación de representaciones semánticas modernas con una estructura jerárquica es superior para desenredar la compleja red de la ciencia moderna.

II. Caracterización de los datos

A continuación se muestran las variables a analizar pertenecientes al dataset, junto con una breve descripción a lo que hacen alusión:

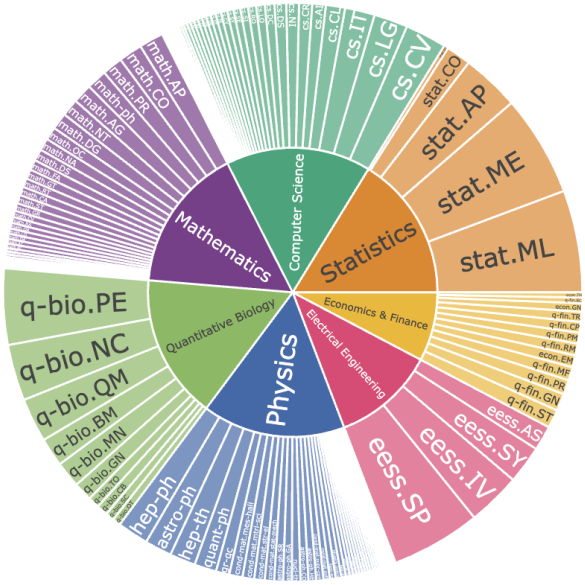

Fig. 1. Grafico sobre las categorias macro y sus respectivas subcategorias.

A. Atributos Categóricos (Texto)

submitter: Autor del paper.

titulo: Nombre/Titulo del paper.

abstract: Abstract del paper.

categories: Categoria y subcategorias asociadas al paper

macro_cat: Representa el dominio disciplinario de nivel superior en la taxonomía de arXiv. Es decir:

$M(x) \in \{\text{Physics, CS, Math, Stat, Q-Bio, EESS, Econ\&Fin}\}$

primary_cat: Representa el dominio disciplinario de nivel inferior en la taxonomía de arXiv.

cleaned_text: Variable "abstract" sometida a una limpieza diseñada para texto formal.

III. Trabajo Relacionado

En el desarrollo de modelos de representación de texto, varios enfoques han sido fundamentales. BERT (Devlin et al., 2018) es un modelo basado en transformadores que aprende representaciones contextuales bidireccionales mediante un preentrenamiento con tareas como el enmascaramiento de palabras y la predicción de la siguiente oración, capturando de forma efectiva el contexto completo de cada palabra. Me base en el trabajo de Cohan et al. (2020) y su modelo SPECTER. A diferencia de los modelos de lenguaje tradicionales como BERT, que se entrenan únicamente con el contexto de las palabras, SPECTER incorpora la señal del grafo de citas durante el pre-entrenamiento, aprendiendo que dos documentos están relacionados si se citan mutuamente, incluso si no comparten el mismo vocabulario exacto. Esta característica fue decisiva para nuestro proyecto, ya que nos permitió generar embeddings estáticos que agrupan naturalmente los documentos por disciplina científica (e.g., separando eficazmente Física de Matemáticas) antes de siquiera entrar a la etapa de clasificación supervisada." Por ultimo, el eje de la organización de textos complejos, el estudio extensivo de Silla y Freitas (2011) sobre clasificación jerárquica estableció las bases teóricas para abordar problemas con un gran número de clases. Su análisis demuestra las limitaciones de los enfoques de 'clasificación plana' cuando se enfrentan a taxonomías profundas, proponiendo en su lugar estrategias como el enfoque 'Local Classifier per Parent Node'. Este trabajo fue fundamental para informar la arquitectura de nuestro proyecto, justificando la división del problema en dos fases distintas: un clasificador general para discriminar entre macro-categorias y clasificadores locales independientes "especialistas" para las subcategorías, reduciendo así la complejidad computacional y la ambigüedad semántica en cada etapa de la inferencia.

IV. Metodología

En esta sección se describe la metodología a seguir para garantizar la calidad de la clasificación jerárquica. Este proceso se dividió en fases estratégicas:

1) **Preprocesamiento** El preprocesamiento es una etapa de Ingeniería de Características (Feature Engineering) y Refinamiento Taxonómico que se divide en 3 partes.
   - **Normalización Taxonómica:** Se detectó que el dataset de arXiv contenía etiquetas obsoletas provenientes de sistemas de clasificación anteriores a la estandarización actual. Para evitar la dispersión de clases y falsos negativos durante la evaluación, implementamos un diccionario de mapeo histórico.
   - **Normalización de texto:** Convertimos todo texto a minúsculas. Transformamos todo el texto a minúsculas para que el modelo no considere palabras como "Good" y "good" como diferentes.
   - **Definición de Targets:** En este proceso, tome las etiquetas originales y las trasnforme en dos variables objetivo distintas:Variable Macro (macro_cat): Se definió una agrupación de alto nivel. Debido a la alta ambigüedad semántica observada entre Economics y Quantitative Finance, se aplicó una estrategia de Fusión de Clases, combinando ambas en una única macro-categoría ("Economics Finance") para mejorar la robustez del clasificador de Fase 1.
     Variable Primaria (primary_cat): Se extrajo la etiqueta de la subcategoria principal normalizada de cada documento, sirviendo como etiquetas de grano fino para los modelos especialistas de la Fase 2.
   - **Limpiezada de texto:** En este proceso se removieron las formulas latex, URL y DOI, también se cuidaron algunos stopwords comunes en articulos cientificos que por lo general seguido de ellos viene información relevante (e.g., "significant", "otherwise", "analysis"), se utilizo spacy para su procesamiento.
   - **Generacion de Embeddings semánticos:** En lugar de utilizar técnicas tradicionales de "Bag-of-Words" que ignoran el contexto, optamos por una representación vectorial densa basada en Transformers.

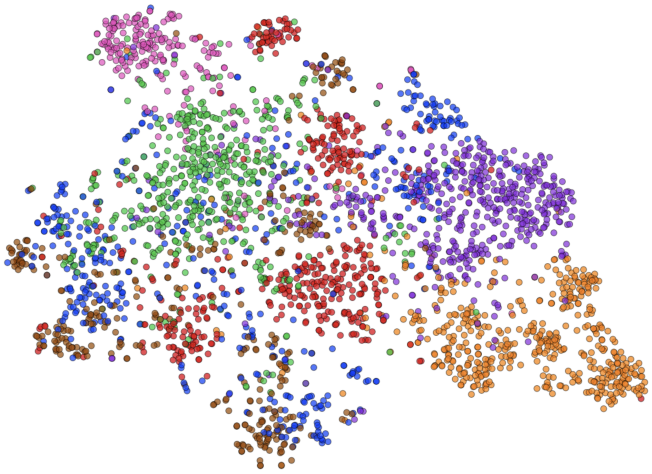

Fig. 2. Visualizacion de categorias en el espacio de los embeddings.

2) **Análisis Exploratorio** El análisis exploratorio de datos en el contexto de mi clasificación jerárquica permite obtener una comprensión inicial de la distribución y características del conjunto de datos. Esta etapa incluye la visualización de la frecuencia de palabras, la proporción de subcategorias y negativos, así como la detección de patrones, sesgos o valores atípicos. Estas observaciones ayudan a orientar decisiones sobre el modelado posterior y a identificar posibles problemas en los datos.
   - **Análisis de longitud de texto:** Es útil conocer la longitud de los textos en el conjunto de datos. Esto puede ayudarte a identificar si ciertos sentimientos tienden a ser más largos o más cortos.
   - **Análisis de palabras y frecuencias:** La visualización de las palabras más frecuentes: Usa una

nube de palabras o un gráfico de barras para visualizar las palabras más comunes.

- **Análisis de densidad de subcategorias:** Filtramos los textos por subcategorias y luego revisa las palabras más frecuentes en cada grupo.
- **Visualización de Sentimiento y Características del Texto :** Usando gráficos de dispersión, boxplots, o violín plots para visualizar cómo varían las características del texto (como la longitud) entre las clases de distintas areas de estudio.

3) **Aplicación de modelos predictivos** Con los embeddings vectoriales generados y la taxonomía normalizada, la estrategia de modelado se diseñó bajo un paradigma de Clasificación Jerárquica Descendente (Top-Down Hierarchical Classification). En contraposición a los clasificadores planos convencionales. Esta arquitectura descompone el problema global en una secuencia de decisiones condicionales. Implementadas mediante redes neuronales independientes para maximizar la precisión en cada nivel de granularidad.

   - **Fase 1: Clasificador General (Modelo A)** El primer nivel de la jerarquía, denominado Modelo A, se implementó como un Perceptrón Multicapa (MLP) que actúa como enrutador global del sistema. Este modelo recibe como entrada los embeddings de 768 dimensiones generados por SPECTER y tiene como objetivo clasificar cada documento en uno de los dominios disciplinarios de nivel superior (macro_cat). La arquitectura consta de capas densas con activación ReLU, optimizadas para capturar relaciones no lineales en el espacio semántico latente. Dado el traslape inherente entre disciplinas afines (particularmente entre Computer Science y Statistics), la lógica de inferencia de este modelo no se limita a la probabilidad máxima (argmax), sino que incorpora un mecanismo de umbral de seguridad (p¿0.30) para clases críticas. Esta estrategia prioriza el Recall en la primera etapa, asegurando que los documentos ambiguos sean canalizados correctamente hacia la siguiente fase en lugar de ser descartados prematuramente.
   - **Fase 2: Clasificadores Especialistas (Modelos B)** La segunda etapa se compone de un conjunto modular de modelos especialistas (Modelos B), donde cada red neuronal es entrenada y validada exclusivamente con el subconjunto de datos correspondiente a una macro-categoría específica. Al aislar el espacio de decisión (e.g., el modelo de 'Física' no procesa vectores de 'Economía'), cada especialista puede enfocar su capacidad de aprendizaje en discernir las sutilezas de grano fino entre subcategorías (primary_cat) sin la interferencia de ruido externo. Estos clasificadores mantienen una arquitectura de red neuronal densa similar a la fase anterior, pero operan sobre un número de clases significativamente reducido y semánticamente coherente. Esta segregación permite trazar fronteras de decisión más precisas entre temas altamente correlacionados.

V. Resultados

La validación del sistema se llevó a cabo en dos niveles. En la primera fase (Modelo A) demostró una alta capacidad para discriminar entre dominios disciplinarios, manteniendo una exactitud global superior al **83%** y logrando rescatar más del **80%** de los documentos en clases críticas como *Computer Science* gracias a la estrategia de umbrales de seguridad. Esta solidez en la etapa inicial fue determinante para minimizar la propagación de errores hacia los modelos especialistas.

TABLE I
Resultados de Clasificación del Modelo A (Fase 1: Macro-Categorías). Perceptrón Multicapa sobre embeddings de SPECTER.

Macro-Categoría	**Precision**	**Recall**	**F1-Score**	**Soporte**
Computer Science	0.75	0.72	0.74	4000
Economics & Finance	0.87	0.89	0.88	1901
Electrical Engineering	0.72	0.80	0.76	2831
Mathematics	0.91	0.85	0.88	4000
Physics	0.94	0.91	0.92	4000
Quantitative Biology	0.86	0.94	0.90	3977
Statistics	0.80	0.78	0.79	4000
Accuracy Global			**0.84**	

Como se detalla en la Tabla I, el clasificador raíz alcanza un rendimiento sobresaliente en dominios bien definidos como Física y Biología. Destaca particularmente la clase fusionada de Economía y Finanzas (F1=0.88), validando la hipótesis de que la consolidación de estas disciplinas reduce la ambigüedad semántica.

Para la evaluación del sistema jerárquico completo (*end-to-end*), se sometió al modelo a una prueba ciega con 1,000 documentos aleatorios no vistos durante el entrenamiento. El sistema alcanzó una **Exactitud Estricta (Top-1 Accuracy)** del **60.9%**, un rendimiento que supera por dos órdenes de magnitud al azar ($< 1\%$) en un espacio de 153 clases. Sin embargo, la métrica más significativa para validar la comprensión semántica del modelo fue la **Exactitud Top-3**, que ascendió al **78.2%**. La brecha de casi 18 puntos porcentuales entre ambas métricas evidencia que la gran mayoría de los errores de clasificación estricta ocurren entre subcategorías semánticamente vecinas, confirmando que el sistema logra capturar correctamente el contexto disciplinario en casi 4 de cada 5 documentos.

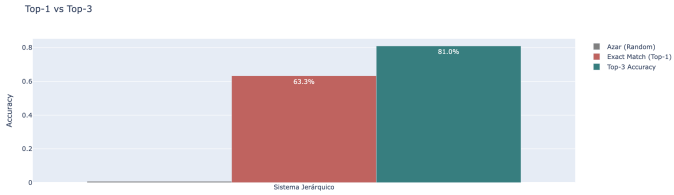

Fig. 3. Grafica que refleja el rendimiento del sistema de clasificacion de texto formal.

VI. Conclusiones

- **Validación de la Arquitectura Jerárquica:** La descomposición del problema de clasificación de 153 categorías en una arquitectura de dos fases (*'Divide y Vencerás'*) demostró ser una estrategia eficaz para mitigar la alta dimensionalidad y el desbalance de clases inherente en arXiv. Al implementar un clasificador "General" robusto en la primera etapa (F1-Score > 0.83), logre aislar semánticamente los dominios de conocimiento, permitiendo que los modelos especialistas de la segunda fase operen en espacios de decisión más limpios y con menor ruido interdisciplinario.
- **Impacto Crítico de la Ingeniería de Datos y Embeddings:** Los resultados evidencian que la calidad de la representación vectorial y la higiene taxonómica son tan importantes como la elección del algoritmo. La utilización de *embeddings* generados por **SPECTER** permitió capturar relaciones semánticas profundas basadas en citas, superando las limitaciones de los métodos basados puramente en frecuencia de palabras. Asimismo, la normalización de etiquetas históricas (e.g., mapeo de *alias*) y la fusión estratégica de las clases *Economics* y *Quantitative Finance* fueron intervenciones decisivas que eliminaron la ambigüedad artificial, incrementando la consistencia del sistema y eliminando los falsos negativos en categorías obsoletas.
- **Interpretación de la Ambigüedad Semántica (Top-1 vs Top-3):** La discrepancia observada entre la Exactitud Estricta (60.9%) y la Exactitud Top-3 (78.2%) revela la naturaleza intrínsecamente interdisciplinaria de la literatura científica moderna. El análisis de errores indica que la mayoría de los fallos del modelo no son aleatorios, sino que ocurren en las fronteras difusas entre sub-disciplinas vecinas (e.g., *Machine Learning* en Ciencias de la Computación vs. Estadística). Esto sugiere que el sistema ha aprendido correctamente la semántica subyacente de los documentos y funciona de manera óptima como un **sistema de recomendación asistida**, capaz de reducir el espacio de búsqueda para un curador humano en casi un 80% de los casos.

References

[1] IBM.
¿Qué es Bag of Words?.
Disponible en: https://www.ibm.com/mx-es/think/topics/bag-of-words.

[2] C. N. Silla y A. A. Freitas.
A survey of hierarchical classification across different application domains.
Data Mining and Knowledge Discovery, 22(1-2), 31-72, 2011.
Disponible en: https://link.springer.com/article/10.1007/s10618-010-0175-9.

[3] A. Cohan, S. Feldman, I. Beltagy, D. Downey, y D. S. Weld.
SPECTER: Document-level Representation Learning using Citation-informed Transformers.
Association for Computational Linguistics (ACL), 2020.
Disponible en: https://arxiv.org/abs/2004.07180.

[4] J. Devlin, M.-W. Chang, K. Lee, y K. Toutanova,
"BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,"
arXiv preprint arXiv:1810.04805, 2019.
Disponible en: https://arxiv.org/pdf/1810.04805.

[5] Ibidem Translations.
Traducción de BERT y ELMo: el contexto es la clave en PLN.
Disponible en: https://www.ibidem-translations.com/edu/traduccion-bert-elmo-pnl/.

[6] EgoCV.
Text Clustering.
Medium, 2019.
Disponible en: https://medium.com/@egocv/text-clustering-cdb6515bdc52.