Divide, Vence y Clasifica: Un Marco Jerárquico, para la Clasificación de Textos Científicos.

Aprendizaje Automático Supervisado
Adquisición y Tratamiento de la Información

Contexto

¿Te imaginas tener que leer miles de artículos científicos para organizarlos por temas?

¿Y si existiera una forma más inteligente de hacerlo?

- El problema es que…

Nuestra propuesta de “Divide, vence y clasidica”

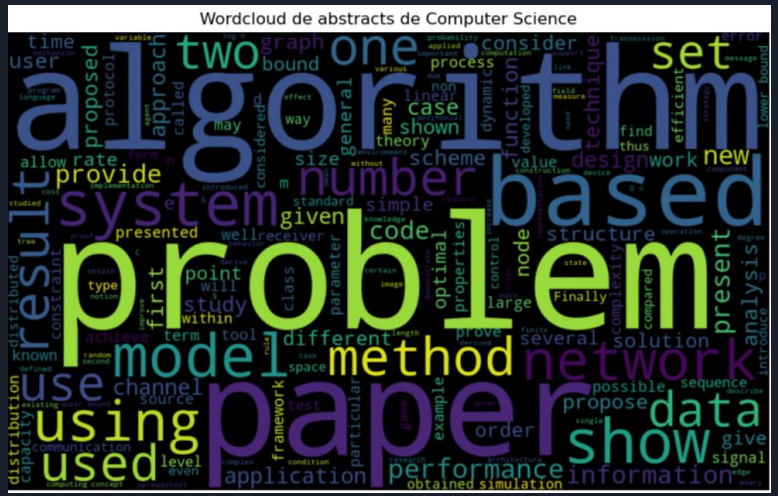
Wordcloud de abstracts de Computer Science
algorithm
problem
based
paper
system
number
model
method
network
using
used
data
show
set
two
one
result
use
provide
new
present
analysis
performance
application
information
simulation
obtained
propose
solution
structure
design
technique
consider
process
bound
graph
time
user
approach
proposed
protocol
general
function
dynamic
shown
case
theory
scheme
size
rate
allow
given
code
optimal
properties
node
large
Finally
compared
several
different
prove
space
channel
source
framework
particular
example
order
possible
sequence
signal
give
level
even
condition
complex
communication
capacity
distribution
constraint
parameter
class
point
will
study
within
first
type
presented
wellreceiver
simulation
work
find
thus
efficient
may
way
many
linear
non
without
knowledge
standard
simple
state
image
random
second
task
defined
existing
test
single
message
edge
event
degree
obtain
tree
notion
variable
program
language
agent
called
considered
effect
measure
field
road
construction
device
computation
applied
various
link
dynamic
developed
dimension
error
lower bound
upper bound
implementation
introduced
m
n
form
studied
operation
computing concept
complexity
introduce
achieve
term
tool
known
random
second
defined
existing
test
complex
condition
single

¿Por qué es tan difícil?

El crecimiento exponencial de la literatura científica (arXiv) dificulta su organización automática.

- Los métodos tradicionales (TF-IDF, Bag-of-Words) “no capturan el sentido semántico” ni las relaciones entre campos.

- Necesidad de modelos que comprendan lenguaje técnico y jerarquías conceptuales.

Objetivos

- Diseñar un sistema jerárquico de clasificación de texto científico basado en Deep Learning.

- Reducir la ambigüedad semántica entre categorías similares.

- Mejorar la precisión y escalabilidad del proceso en comparación con métodos planos.

Divide y Vence

- Inspirado en la estrategia de descomponer un problema complejo en subproblemas.

- Dos niveles de clasificación:
  1. Modelo a: Clasificador general por grandes dominios (Physics, Math, CS, etc.)
  2. Modelo b: Clasificadores especializados por subcategoría (Stat.ML, CS.LG, etc.).

Metodología

Incluye tres etapas principales:

1. **Preprocesamiento** y normalización del texto limpieza, estandarización de etiquetas).
2. **Generación de embeddings** semánticos con “SPECTER” (modelo Transformer).
3. **Entrenamiento jerárquico** usando redes neuronales independientes para cada nivel.

Que se utilizó?

Mucho Entusiasmo

	submitter	title	abstract	categories	main_cat	sub_cat
0	Pavel Nadolsky	Calculation of prompt diphoton production cros...	A fully differential calculation in perturba...	hep-ph	hep-ph	hep-ph
1	Louis Theran	Sparsity-certifying Graph Decompositions	We describe a new algorithm, the (k, ℓ) -...	math.CO cs.CG	math	math.CO
2	Hongjun Pan	The evolution of the Earth-Moon system based o...	The evolution of Earth-Moon system is descri...	physics.gen-ph	physics	physics.gen-ph
3	David Callan	A determinant of Stirling cycle numbers counts...	We show that a determinant of Stirling cycle...	math.CO	math	math.CO
4	Alberto Torchinsky	From dyadic Λ_α to $\Lambda_{\a...	In this paper we show how to compute the $\L...	math.CA math.FA	math	math.CA
...	...	...	...	...	...	...
1747302	Ruslan Prozorov	On the origin of the irreversibility line in t...	We report on measurements of the angular dep...	supr-con cond-mat.supr-con	supr-con	supr-con
1747303	Durga P. Choudhury	Nonlinear Response of HTSC Thin Film Microwave...	The non-linear microwave surface impedance o...	supr-con cond-mat.supr-con	supr-con	supr-con
1747304	Durga P. Choudhury	Critical State Flux Penetration and Linear Mic...	The vortex contribution to the dc field (H) ...	supr-con cond-mat.supr-con	supr-con	supr-con
1747305	Hasegawa Yasumasa	Density of States and NMR Relaxation Rate in A...	We show that the density of states in an ani...	supr-con cond-mat.supr-con	supr-con	supr-con
1747306	Masanori Ichioka	Ginzburg Landau theory for d-wave pairing and ...	The Ginzburg Landau theory for d_{x^2-y^2}-w...	supr-con cond-mat.supr-con	supr-con	supr-con

1747307 rows × 6 columns

Distribución Jerárquica de Macro Cat a Subcat

Representaciones

- Dataset basado en artículos de arxiv-metadata-oai-snapshot-2020-08-14.json.

- Se eliminaron ambigüedades y se redefinieron categorías superpuestas (como “Economics” + “Quantitative Finance”).

- **SPECTER embeddings** permiten representar significados y relaciones entre textos de distintas disciplinas.

Se utilizó MLP.

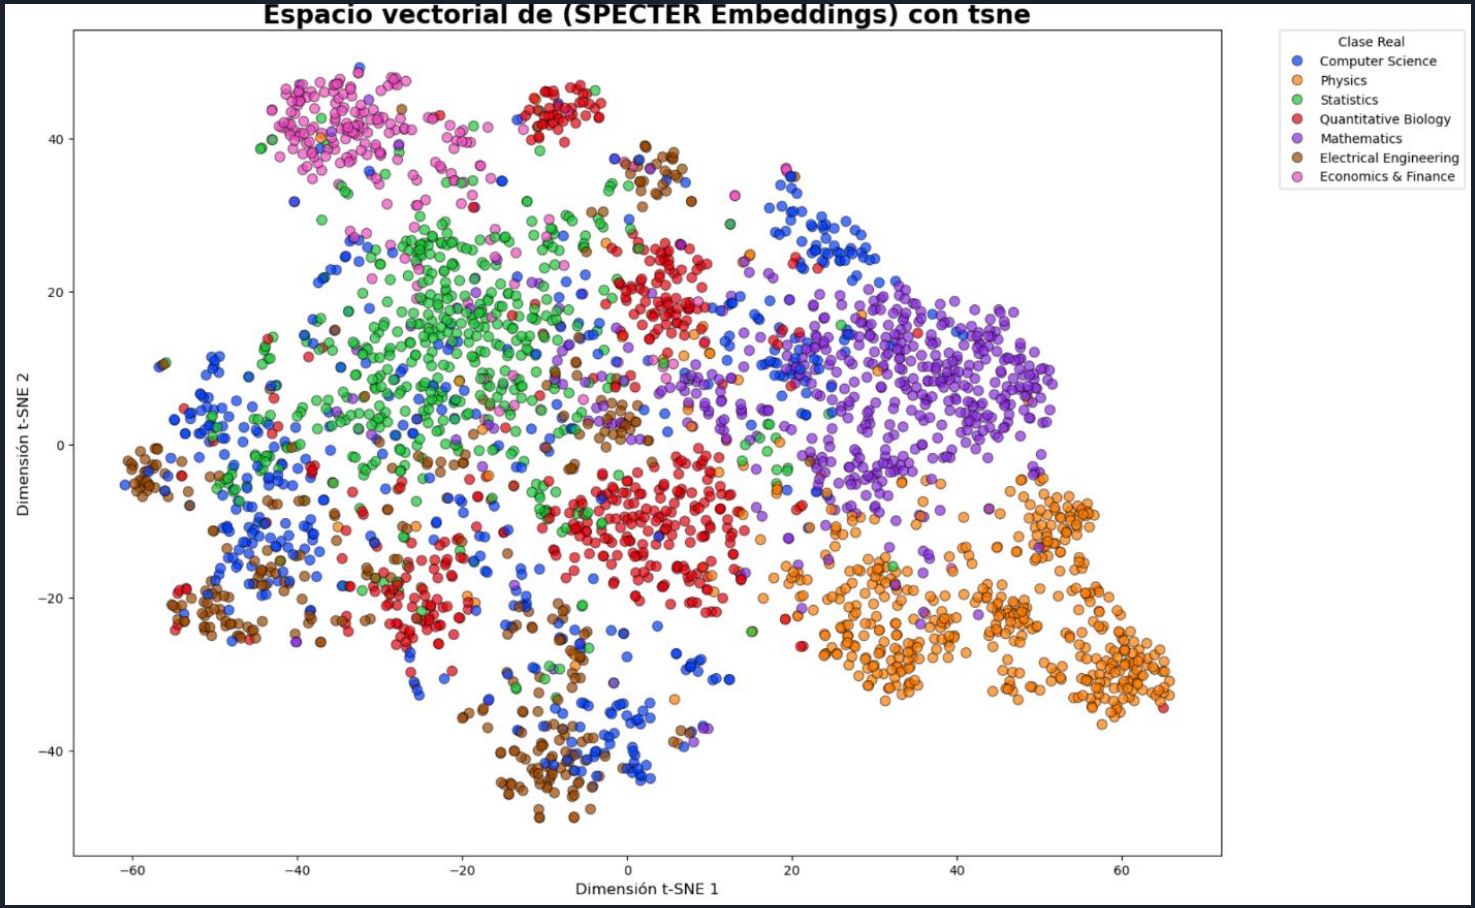
Espacio vectorial de (SPECTER Embeddings) con tsne
Clase Real
Computer Science
Physics
Statistics
Quantitative Biology
Mathematics
Electrical Engineering
Economics & Finance
Dimensión t-SNE 2
Dimensión t-SNE 1
40
20
0
−20
−40
−60
−40
−20
0
20
40
60

TABLE I

RESULTADOS DE CLASIFICACIÓN DEL MODELO A (FASE 1: MACRO-CATEGORÍAS). PERCEPTRÓN MULTICAPA SOBRE EMBEDDINGS DE SPECTER.

Macro-Categoría	**Precision**	**Recall**	**F1-Score**	**Soporte**
Computer Science	0.75	0.72	0.74	4000
Economics & Finance	0.87	0.89	0.88	1901
Electrical Engineering	0.72	0.80	0.76	2831
Mathematics	0.91	0.85	0.88	4000
Physics	0.94	0.91	0.92	4000
Quantitative Biology	0.86	0.94	0.90	3977
Statistics	0.80	0.78	0.79	4000
Accuracy Global		**0.84**		

Resultados Clave

- **Fase 1:** F1-score = 0.83, alto rendimiento en dominios amplios.

- Sistema completo:
  - Top-1 Accuracy: 69.9%
  - Top-3 Accuracy: 78.2%

- Reduce errores entre categorías relacionadas y mejora la coherencia semántica.

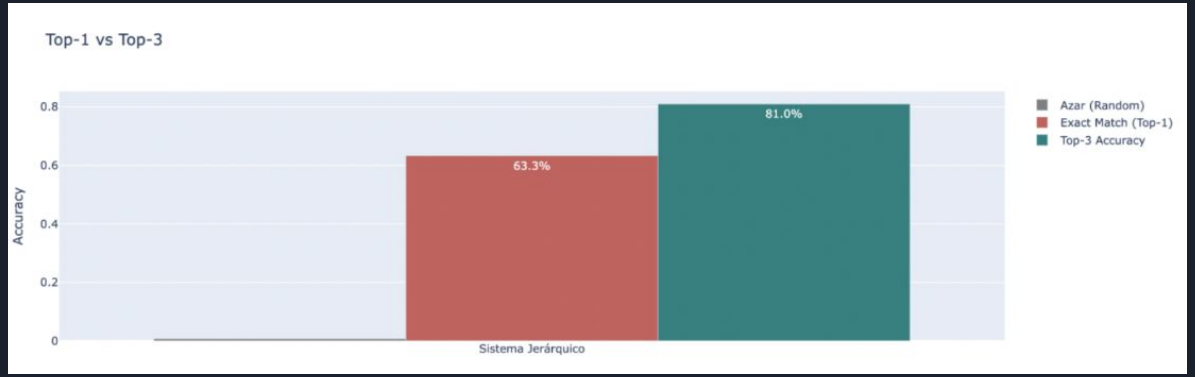

Conclusiones

- El enfoque jerárquico es eficaz para manejar la complejidad y el desbalance de clases.

- El uso de representaciones semánticas profundas (Transformers) fue clave.

- Reduce la ambigüedad interdisciplinaria y mejora la precisión frente a métodos clásicos.

Esta grafica sera la prueba de que mi proyecto fue un exito.

La barra gris, aunque no se vea mucho, son los papers que no se supieron clasificar y se asignaron al azar

La barra roja, ese 60.9% representa las veces que el modelo acerto a la primera con seguridad. (por ejemplo, el paper de prueba era cs.AI y el modelo dijo con seguridad que es cs.AI) este modelo sufrio bastante por la ambiguedad de arxiv, ya que si el modelo dijo que el paper era cs.LG (machine learning) y el paper era stat.ML (machine learning pero en estadisica) el fallo contara como un cero

La barra verde, ese 78.2% es el caso en el que mejor le va al modelo. representa las veces que la respuesta correcta estaba entre las 3 opciones que el modelo considero mas probables, es prueba de que el sistema SI es inteligente.

Esta diferencia entre barra roja y verde significa una cosa, no es que el modelo se equivoque profundamente (por ejemplo, diciendo que un paper es de finanzas cuando en realidad es de biologia), es por que duda de cosas muy parecidas, como ya se conto anteriormente.